



Chapter 9

Searching

Searching

- เราสามารถใช้คอมพิวเตอร์มาช่วยประมวลผลงานทุกอย่างไป เช่น การเก็บข้อมูลต่างๆ ซึ่งมักมีขนาดใหญ่ และมีความจำเป็นต้องเรียกใช้เสมอ
- ผู้ใช้ต้องสามารถจัดการข้อมูล ทั้งการเพิ่ม, แก้ไข หรือลบข้อมูลที่มีได้อย่างรวดเร็ว
- นั่นคือ จำเป็นต้องมีอัลกอริทึมที่ช่วยในการค้นหา (Searching) ข้อมูลได้อย่างรวดเร็ว ซึ่งจะทำให้การจัดการข้อมูลต่างๆ มีประสิทธิภาพมากยิ่งขึ้น

Basic Search Algorithm

- Sequential Search
- Binary Search
- Hashing

Sequential Search

- เป็นการค้นหาข้อมูลในลักษณะเรียงลำดับ โดยไล่เปรียบเทียบตั้งแต่ข้อมูลตัวแรก ตัวที่สอง ไล่ไปเรื่อยๆ จนกว่าจะพบข้อมูลที่ต้องการ
- ในกรณีที่ ไล่เปรียบเทียบจนถึงข้อมูลตัวสุดท้ายแล้วยังไม่พบข้อมูลที่ต้องการ แสดงว่าไม่มีข้อมูลดังกล่าว

Sequential Search (Cont.)

- ต้องการค้นหาข้อมูลที่มีค่า 14 จากชุดข้อมูล







Sequential Search Algorithm in an Unordered List

```
Algorithm seqSearch1(list, last, target)
1   set looker to 0
2   loop (looker < last AND target not equal list[looker])
    1   increment looker
3   end loop
4   set loc to looker
5   if (target equal list[looker])
    1   set found to loc
6   else
    1   set found to false
7   end if
8   return found
End seqSearch1
```

Target given: 14
Location found: 3
last = 11

Successful Search of an Unordered List



Target given: 72
last = 11

Unsuccessful Search in an Unordered List

looker

0

a[0] a[1] a[2] a[3] a[4] a[5] a[6] a[7] a[8] a[9] a[10] a[11]

72 is not equal to 4

4	21	36	14	62	91	8	22	7	81	77	10
---	----	----	----	----	----	---	----	---	----	----	----

looker

1

a[0] a[1] a[2] a[3] a[4] a[5] a[6] a[7] a[8] a[9] a[10] a[11]

72 is not equal to 21

4	21	36	14	62	91	8	22	7	81	77	10
---	----	----	----	----	----	---	----	---	----	----	----

looker

5

a[0] a[1] a[2] a[3] a[4] a[5] a[6] a[7] a[8] a[9] a[10] a[11]

72 is not equal to 91

4	21	36	14	62	91	8	22	7	81	77	10
---	----	----	----	----	----	---	----	---	----	----	----

looker

11

a[0] a[1] a[2] a[3] a[4] a[5] a[6] a[7] a[8] a[9] a[10] a[11]

72 is not equal to 10

4	21	36	14	62	91	8	22	7	81	77	10
---	----	----	----	----	----	---	----	---	----	----	----

Sequential Search Algorithm in an Ordered List

Algorithm seqSearch2(list, last, target)

```
1   set looker to 0
2   loop (looker < last AND loop is TRUE)
    1   if (target is equal to list[looker])
        1   set loc to looker
        2   set loop to FALSE
    2   else
        1   if (list[looker] > target)
            1   set loop to FALSE
        2   else
            1   increment looker
3   end loop
4   return loc
End seqSearch2
```

Search Algorithm Analysis

- วิเคราะห์ประสิทธิภาพของการค้นหา พิจารณาแบ่งเป็น 3 กรณี
 - กรณีดีที่สุด (Best Case)
 - กรณีแย่ที่สุด (Worst Case)
 - กรณีเฉลี่ย (Average Case)

Sequential Search Algorithm Analysis

- กรณีดีที่สุด สามารถค้นพบข้อมูลที่ต้องการได้ทันที (พบข้อมูลตั้งแต่ครั้งแรก)
 - ทำการเปรียบเทียบแค่ 1 ครั้ง
- กรณีแย่ที่สุด ต้องทำการเปรียบเทียบข้อมูลไปจนถึงตัวสุดท้ายจึงจะพบ
 - ทำการเปรียบเทียบ N ครั้ง (มีข้อมูลทั้งหมด N ข้อมูล)
- กรณีเฉลี่ย หาโดยนำผลรวมของการเปรียบเทียบไปยังข้อมูลแต่ละตัว แล้วหารด้วยจำนวนข้อมูล
 - ทำการเปรียบเทียบเฉลี่ย $(1+2+\dots+N)/N = (N+1)/2$ ครั้ง

The Big-O Notation

- การวิเคราะห์ประสิทธิภาพของการค้นหาข้อมูล จะเน้นที่ชุดข้อมูลที่มีจำนวนมากๆ ซึ่งมีผลกระทบต่อเวลาในการทำงานโดยรวมมากขึ้น
- การวัดประสิทธิภาพในการค้นหาข้อมูล จะใช้ค่าประมาณซึ่งพิจารณาจากค่าที่มีผลกระทบมากที่สุด ตามแนวคิดของบิกโอ (Big O)
- เช่น $f(N) = N^4 + 10N - 5$, $f(n) = O(N^4)$

Big-O of Sequential Search

- Best Case
 - เปรียบเทียบ 1 ครั้ง
 - $O(1)$
- Average Case
 - เปรียบเทียบเฉลี่ย $(N+1)/2$
 - $O(N)$
- Worst Case
 - เปรียบเทียบ N ครั้ง
 - $O(N)$

Binary Search

- การค้นหาแบบ Sequential ง่าย แต่เสียเวลามาก (ลองนึกถึงกรณีที่มีข้อมูลมากๆ)
- การค้นหาที่มีประสิทธิภาพมากขึ้น ได้แก่ การค้นหาแบบ Binary Search
- เป็นการค้นหาที่ใช้กับชุดข้อมูลที่มีการเรียงลำดับเท่านั้น

Binary Search (cont.)

- ทำการเปรียบเทียบข้อมูลที่ต้องการกับข้อมูลที่อยู่ตำแหน่งกึ่งกลางของชุดข้อมูลทั้งหมด
- ถ้าไม่เท่ากัน (ไม่พบ) ให้ไล่เปรียบเทียบไปเรื่อยๆ จนกว่าจะพบหรือไม่สามารถแบ่งครึ่งชุดข้อมูลได้อีก โดยกำหนดว่าหาก
 - ค่าที่ต้องการค่าน้อยกว่า ให้เปรียบเทียบกับจุดกึ่งกลางของข้อมูลครึ่งแรกของชุดข้อมูลที่พิจารณา และไม่สนใจข้อมูลครึ่งหลังอีก
 - ค่าที่ต้องการค่านามากกว่า ให้เปรียบเทียบกับจุดกึ่งกลางของข้อมูลครึ่งหลังของชุดข้อมูลที่พิจารณา และไม่สนใจข้อมูลครึ่งแรกอีก
- ตำแหน่งกึ่งกลาง : $\lfloor (\text{begin} + \text{end}) / 2 \rfloor$


Binary Search Algorithm

Algorithm binarySearch(list, last, target)


```
1   set begin to 0
2   set end to last
3   loop (begin <= end)
    1   set mid to (begin+end)/2
    2   if (target > list[mid])
        1   set begin to mid+1
    3   else if (target < list[mid])
        1   set end to mid-1
    4   else
        1   set begin to (end+1)
    5   end if
4   end loop
5   set loc to mid
6   if (target is equal to list[mid])
    1   set found to TRUE
7   else
    1   set found to FALSE
8   end if
9   return found
End binarySearch
```


Successful Binary Search Example


Target given: 22
Location found: 6



22 > 21



22 < 62




22 equals 22




Unsuccessful Binary Search Example


Target given: 11



$11 < 21$





$11 > 8$



$11 > 10$

Unsuccessful Binary Search Example (cont.)

Target given: 11



Big-O of Binary Search

- Best Case

- เปรียบเทียบ 1 ครั้ง ข้อมูลที่ต้องการอยู่กึ่งกลางพอดี
- $O(1)$

↓
ข้างกลางพอดี

10 20 30 40 50 60 70

- Average Case

- เปรียบเทียบเฉลี่ย $(2^0 \cdot 1 + 2^1 \cdot 2 + 2^2 \cdot 3 + \dots + 2^m \cdot (m+1)) / N$
(m = ระดับของต้นไม้) *node level*

$(2^{0*1} + 2^{1*2} + 2^{2*3})$
 ↳ node no. level
 ↳ no. of children

$\log_2$

$$\sqrt{-2.7}$$

- $O(\log_2 N)$

- Worst Case

- เปรียบเทียบโดยแบ่งข้อมูลออกเป็นชุดย่อยๆ จนเหลือตัวเดียว
- $O(\log_2 N)$

Comparison of Binary and Sequential Searches


Element size	Iterations	
	Binary	Sequential
16	4	16
50	6	50
256	8	256
1,000	10	1,000
10,000	14	10,000
100,000	17	100,000
1,000,000	20	1,000,000

Hashing

key-value

- ต้องการให้การค้นหาข้อมูลมีประสิทธิภาพเป็น $O(1)$ นั่นคือสามารถเข้าถึงข้อมูลได้โดยตรง
- **หลักการ**
 - ข้อมูลที่จะนำเข้า หรือค้นหา จะเรียกว่า คีย์ (key)
 - ใช้ Hash Function หาตำแหน่งของคีย์นั้นที่เก็บข้อมูล ซึ่งเรียกว่า ตารางแฮช (Hash Table)

Hashing (cont.)



Collision

- **ปัญหา** อาจเกิดการชนกันของข้อมูล นั่นคือ คีย์ไม่เหมือนกันแต่แฮชแล้วได้ค่าเดียวกันในตารางแฮช
- เช่น กำหนด Hash Function เป็นการ mod ด้วย 100 และมีคีย์เป็น 10275 และ 27675 เมื่อผ่านการแฮชแล้วจะได้ 75 เหมือนกัน -> เกิดการชนกัน
- การหลีกเลี่ยงการชนกัน (Collision)
 - กำหนด Hash Function ให้ดี
 - นำคีย์ไปแฮชอีกครั้ง เรียกว่า Rehashing


Collision Resolution

- Linear Probing
- Buckets
- Chaining (Linked List Collision Resolution)

Linear Probing

Insert

- กรณีที่นำข้อมูลเข้า เมื่อแฮชแล้วเกิดการชนกัน ให้หาตำแหน่งที่ว่างถัดไปเพื่อเพิ่มข้อมูล



Linear Probing


Search

- ในกรณีที่ต้องการค้นหาข้อมูล
 - นำคีย์ไปผ่าน Hash Function ถ้าเจอข้อมูลที่มีคีย์ตรงกันแสดงว่าหาเจอ
 - ถ้าไม่ใช่คีย์ที่ต้องการ ให้ไล่ไปตำแหน่งถัดไปเรื่อยๆ จนกว่าจะเจอ
 - แต่ถ้าเจอช่องว่าง แสดงว่า ไม่มีข้อมูลนั้น
- เมื่อเกิดการชนกัน จะไล่ไปตำแหน่งถัดไป นั่นก็คือ การทำ Rehashing ด้วยฟังก์ชัน
 - $(\text{ตำแหน่งที่แฮชได้} + \text{ค่าคงที่}) \% \text{ขนาดอาร์เรย์}$
- การ Hashing เป็นวิธีที่ดี แต่เมื่อเกิดการชนกันมากขึ้น จะทำให้ประสิทธิภาพการค้นหาข้อมูลแยกลง

Buckets

- คีย์ที่ผ่านการแฮชแล้วได้ค่าเหมือนกัน สามารถเก็บอยู่ในตำแหน่งเดียวกันได้ ซึ่งมีการกำหนดจำนวนของคีย์ที่ตำแหน่งเดียวกันชัดเจน
- เช่น กำหนดให้มีคีย์ที่ตำแหน่งเดียวกันไม่เกิน 3 คีย์
- เก็บข้อมูลตารางแฮชเป็นแบบอาร์เรย์ 2 มิติ
- **ปัญหา** หากมีคีย์ที่แฮชแล้วจะอยู่ตำแหน่งเดียวกันมากกว่าที่กำหนด ก็เกิดการชนกันอีก

Buckets (cont.)




000	Bucket 0	379400	Mary Dodd
001	Bucket 1	070901	Sam Apple
		166701	Harry Eagle
002	Bucket 2	121202	Bryan Devaux
		572502	Chris Waljasper
		634902	Ann Giorgis
	...		
099	Bucket 99	045199	Charlie Feldman

Hash Table

Chaining

- คีย์ที่ผ่านการแฮชแล้วได้ค่าเหมือนกัน สามารถเก็บอยู่ในตำแหน่งเดียวกันได้ *โดยไม่จำกัดจำนวน*
- เก็บข้อมูลตารางแฮชเป็นแบบลิงค์ลิสต์

Chaining (cont.)



Quiz

- หากกำหนดให้อาร์เรย์ มีค่าข้อมูลดังนี้

18 13 17 26 44 56 88 97

ให้ใช้วิธี Sequential Search และ Binary Search ในการ
ค้นหา

- ข้อมูล 56
- ข้อมูล 20

(ให้เขียนการค้นหาเป็นลำดับขั้นตอน และสรุปด้วยว่าต้องมีการ
เปรียบเทียบกี่ครั้งจึงจะพบข้อมูลที่ต้องการ)

Quiz

- ให้เก็บข้อมูลเหล่านี้ลงในตารางแฮชขนาด 20 ช่อง โดยใช้วิธี Linear Probing
 - กำหนดให้ใช้ Hash Function แบบ Modulo-division (ลำดับของข้อมูลเรียงลำดับจากซ้ายไปขวา จากบนลงล่าง)

224562	137456	214562
140145	214576	162145
144467	199645	234534

- การทำงานดังกล่าว ทำให้เกิดการชนกันของข้อมูลกี่ครั้ง อย่างไร