



Lecture Notes

ความน่าจะเป็นและสถิติ

Probability and Statistics

ศาสตราจารย์ ดร. สุขสันต์ พาณิชพาพิบูล

คณะเทคโนโลยีสารสนเทศ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

บทที่ 8

สถิติเบื้องต้น (Basic Statistics)

ในบทนี้เราจะศึกษาเกี่ยวกับหลักการและข้อมูลทางสถิติเบื้องต้น ซึ่งประกอบไปด้วยหัวข้อต่างๆ ดังนี้

- หลักแนวคิดของสถิติ
- สถิติสรุป (Summary Statistics)
- ข้อมูลสรุปเชิงภาพ (Graphical Summaries)

8.1 หลักแนวคิดของสถิติ

ปูจฉฉ 8.1 หลักแนวคิดของสถิติคืออะไร เราเรียนสถิติไปเพื่ออะไร?

วศัชนฉ หลักแนวคิดพื้นฐานฉคัญของสถิติก็คือ การอนุมาน (Infer) เกี่ยวกับลักษณะของประชากร (Population) โดยใช้กลุ่มตัวอย่าง (Sample) เพียงบางส่วนจากประชากรนั้น ยกตัวอย่างเช่น เราอาจต้องการทราบฉาโดยเฉลี่ยแล้วประชากรในประเทศไทยมีความสูงเท่าใด วิธีการให้ได้มาซึ่งคำตอบนี้ก็คือจะต้องไปสอบถามประชากรทุกคนในประเทศไทย (ประมาณ 70 ล้านคน) ฉาแต่ละคนมีความสูงเท่าใดแล้วจึงมาหาค่าเฉลี่ย ซึ่งจะเห็นว่าในทางปฏิบัติฉนั้นกระทำจริงได้ยาก และอาจสัฉเปลืองงบประมาณเกินความจำเป็น อย่างไรก็ตาม เราสามารถแก้ปัญหาฉนี้ได้โดยใช้วิธีการทางสถิติ กล่าวคือเราอาจไปสุ่มเลือกคนไทยมา 1,000 คนเพื่อเป็นกลุ่มตัวอย่าง แล้วจึงหาค่าเฉลี่ยความสูงของคนในกลุ่มที่สุ่มเลือกมา โดยมีสมมติฐานฉาความสูงเฉลี่ยของคนในกลุ่มฉนี้ฉาจะใกล้เคียงกับความสูงเฉลี่ยที่วัดได้จริงจากประชากรทั้ง 70 ล้านคน

การเรียนหลักวิชาการศึกษาทางสถิติจะช่วยให้เรามีเครื่องมือในการหาคำตอบเกี่ยวกับประชากร (ซึ่งอาจจะมีจำนวนมาก) โดยใช้กลุ่มตัวอย่าง (ซึ่งมีจำนวนน้อย) ได้

เนื้อหาในบทนี้อ้างอิงจาก [4]

ปูจฉฉ 8.2 ประชากร (Population) คืฉฉไร?

วิธีฉฉฉฉา ประชากร คืฉฉ ผลการทดลองทังหมดเก็ยวกับข้อมูลที่เราต้องการหา เช่น เราอาจต้องการทราบความสูงของประชากรในประเทศไทย ประชากรในกรณีนี้ก็คือความสูงของคนไทยทังประเทศ (70 ล้านคน)

ปูจฉฉ 8.3 กลุ่มตัวอย่าง (Sample) คืฉฉไร?

วิธีฉฉฉฉา กลุ่มตัวอย่าง คืฉฉ ซึบเซ็ดของประชากร ซึ่งเป็นผลการทดลองที่เราสังเกตหรือได้มา เช่น ความสูงของคนไทยที่สุ่มเลือกมาเป็นกลุ่มตัวอย่าง

ปูจฉฉ 8.4 การสุ่ม (Sampling) คืฉฉไร?

วิธีฉฉฉฉา การสุ่ม (Sampling) คืฉฉ การเลือกกลุ่มตัวอย่างบางส่วนออกมาจากประชากรทังหมด

ปูจฉฉ 8.5 การสุ่มอย่างง่าย (Simple Random Sampling) คืฉฉไร?

วิธีฉฉฉฉา การสุ่มอย่างง่าย (Simple Random Sampling) คืฉฉ การสุ่มเลือกที่โอกาสจะได้ตัวอย่างใดๆจากประชากรทังหมด มีโอกาสเกิดขึ้นได้เท่าๆกัน คล้ายๆกับการจับฉลากอย่างง่ายๆ นั้นเอง

8.2 สถิติสรุป (Summary Statistics)

โดยมากแล้วข้อมูลที่เราต้องการหาคำตอบหรือนำมาวิเคราะห์นั้นจะประกอบไปด้วยข้อมูลจำนวนมาก ซึ่งบางทียากต่อการทำความเข้าใจเบื้องต้น ดังนั้นจึงมีการคิดสิ่งทีเรียกว่าสถิติสรุปขึ้นมาเพื่อใช้บอกลักษณะคร่าวๆ โดยสรุปของข้อมูล สถิติสรุปที่นิยมใช้กัน เช่น ค่าเฉลี่ย ค่ามัธยฐาน ค่าเบี่ยงเบนมาตรฐาน

ปูจฉฉ 8.6 ข้อมูล (Data) แบ่งออกหลักๆ ได้กี่ชนิด ฉฉไรบ้าง?

วิธีฉฉฉฉา ข้อมูล แบ่งออกหลักๆ ได้เป็น 2 ชนิด ดังนี้

1. ข้อมูลเชิงปริมาณ (Quantitative Data) หรือข้อมูลที่เป็นตัวเลข (Numerical Data) เช่น ความสูงของนักเรียน อุณหภูมิ จำนวนผู้เข้าชมเว็บไซต์ในหนึ่งวัน
2. ข้อมูลเชิงคุณภาพ (Qualitative Data) หรือข้อมูลที่เป็นการแบ่งประเภท (Categorical Data) ซึ่งยังแยกย่อยได้เป็น 2 ชนิดคือ
 - ชนิดไม่มีความสัมพันธ์เชิงลำดับ เช่น เพศ (ชาย, หญิง) กลุ่มเลือด (AB, A, B, O)

- ชนิดมีความสัมพันธ์เชิงลำดับ เช่น ระดับการศึกษา (อนุบาล, ประถม, มัธยม) จะเห็นว่ามีความสัมพันธ์เชิงลำดับกล่าวคือ มัธยมมีระดับสูงกว่าประถม หรือขนาดเสื้อ (S, M, L, XL) จะเห็นว่าขนาด XL ใหญ่กว่าขนาด M เป็นต้น

ปูจจา 8.7 ค่าเฉลี่ยตัวอย่าง (Sample Mean) คืออะไร หาอย่างไร?

วิสัยทัศน์ ค่าเฉลี่ยตัวอย่าง คือ ค่าเฉลี่ยของข้อมูลที่อยู่ในกลุ่มตัวอย่าง บางทีอาจเรียกว่าค่าเฉลี่ยเลขคณิต (Arithmetic Mean) ก็ได้ ซึ่งมีวิธีการหาดังนี้

กำหนด $X_1, X_2, \dots, X_n$ เป็นข้อมูลในกลุ่มตัวอย่าง ค่าเฉลี่ยตัวอย่างหาได้ดังนี้

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

ตัวอย่าง 8.1 นักเรียน 5 คนในโรงเรียนถูกสุ่มมาเป็นกลุ่มตัวอย่าง นักเรียนแต่ละคนมีน้ำหนักในหน่วยกิโลกรัมดังนี้ 45, 49, 55, 41, 62 จงหาค่าเฉลี่ยตัวอย่างของน้ำหนักนักเรียน

วิธีทำ หาได้ดังนี้

$$\begin{aligned} \bar{X} &= \frac{1}{5} \times (45 + 49 + 55 + 41 + 62) \\ &= 50.4 \end{aligned}$$

ปูจจา 8.8 ค่าความแปรปรวนตัวอย่าง (Sample Variance) คืออะไร หาอย่างไร?

วิสัยทัศน์ ค่าความแปรปรวนตัวอย่าง คือ ค่าตรรกะที่ใช้วัดการกระจายตัวของข้อมูลในกลุ่มตัวอย่าง ซึ่งหาได้ดังนี้

กำหนด $X_1, X_2, \dots, X_n$ เป็นข้อมูลในกลุ่มตัวอย่าง ค่าความแปรปรวนตัวอย่างหาได้ดังนี้

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

หรืออาจหาตามสมการนี้ก็ได้เช่นกัน

$$s^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

ปูจจา 8.9 ค่าเบี่ยงเบนมาตรฐานตัวอย่าง (Sample Standard Deviation) คืออะไร หาอย่างไร?

วิธีชนา ค่าเบี่ยงเบนมาตรฐานตัวอย่าง คือ รากที่สองของค่าความแปรปรวนตัวอย่าง ซึ่งหาได้ดังนี้
กำหนด $X_1, X_2, \dots, X_n$ เป็นข้อมูลในกลุ่มตัวอย่าง ค่าเบี่ยงเบนมาตรฐานตัวอย่างหาได้ดังนี้

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

หรืออาจหาตามสมการนี้ก็ได้เช่นกัน

$$s = \sqrt{\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)}$$

ปฏจนา 8.10 ทำไมเวลาคำนวณหา s^2 กับ s ต้องหารด้วย $n-1$ แทนที่จะหารด้วย n ?

วิธีชนา เวลาคำนวณหา s^2 เราได้ใช้ค่าเฉลี่ยตัวอย่าง $\bar{X}$ แทนที่จะใช้ค่าเฉลี่ยที่แท้จริงของประชากร โดยปกติแล้ว ความเบี่ยงเบนจากค่าเฉลี่ยตัวอย่างมักจะน้อยกว่าความเบี่ยงเบนจากค่าเฉลี่ยที่แท้จริงของประชากร การหารด้วย $n-1$ แทนที่จะหารด้วย n ช่วยมาแก้ไขการคำนวณตรงนี้ให้ถูกต้อง

ตัวอย่าง 8.2 จากตัวอย่าง 8.1 จงหาค่าความแปรปรวนตัวอย่าง และค่าเบี่ยงเบนมาตรฐานตัวอย่าง

วิธีทำ หาค่าความแปรปรวนตัวอย่างได้ดังนี้

$$\begin{aligned} s^2 &= \frac{1}{4} ((45 - 50.4)^2 + (49 - 50.4)^2 + (55 - 50.4)^2 + (41 - 50.4)^2 + (62 - 50.4)^2) \\ &= \frac{275.2}{4} \\ &= 68.8 \end{aligned}$$

ค่าเบี่ยงเบนมาตรฐานตัวอย่าง $s = \sqrt{68.8} = 8.2946$

ปฏจนา 8.11 การคูณและบวกข้อมูลในกลุ่มตัวอย่างด้วยค่าคงที่ ส่งผลอย่างไรต่อค่าเฉลี่ยตัวอย่างและค่าความแปรปรวนตัวอย่าง?

วิธีชนา ส่งผลดังนี้

กำหนด $X_1, X_2, \dots, X_n$ เป็นข้อมูลในกลุ่มตัวอย่าง และ $Y_i = aX_i + b$ โดยที่ a, b เป็นค่าคงที่ ค่าเฉลี่ยเปลี่ยนไปดังนี้คือ

$$\bar{Y} = a\bar{X} + b$$

ค่าความแปรปรวนเปลี่ยนไปดังนี้คือ

$$s_Y^2 = a^2 s_X^2$$

ปูจฉฉ 8.12 ข้อมูลผดปกต (Outliers) คืฉฉไร?

วิธีชนฉฉ ข้อมูลผดปกต คืฉฉ ข้อมูลที่มีค่าสูงกวฉฉหรือต่ำกวฉฉข้อมูลอื่นที่อยูฉฉในกลุ่ฉฉเดียวกันมากๆ ซึ่งอาจเกิดขึ้นได้จริง หรืออาจเกิดมาจากความผดพลฉฉของการบันทึฉฉข้อมูล เช่น กลุ่ฉฉตัวอย่างของนักเรียน 6 คนมีน้ำหนักในหน่วยกิโลกรัมคืฉฉ 45, 49, 55, 41, 62, 705 จะเห็นวฉฉในกรณีนี้มีข้อมูลที่ผดปกตคืฉฉ 705 เนื่องจากมีค่าสูงผดปกตกวฉฉค่าอื่นในกลุ่ฉฉมาก ในกรณีนี้ฉฉอาจสันนิษฐานวฉฉ เกิดจากความผดพลฉฉในการบันทึฉฉข้อมูลเพราะในความเป็นจริงแล้วไม่นฉฉจะมีนักเรียนที่มีน้ำหนักมากถึง 705 กิโลกรัม อยฉฉงไรก็ตามข้อมูลที่เปฉฉ็นข้อมูลผดปกตนั้นในหลายกรณีก็อาจจะเป็นข้อมูลที่มิฉฉทธิเกิดขึ้นได้จริง ฉฉงนั้นต้องใชฉฉความระมัดระวังในการพิจารณาด้วย

ปูจฉฉ 8.13 ค่ำฉฉมัธยฐานตัวอย่าง (Sample Median) คืฉฉไร หาได้อย่างไร?

วิธีชนฉฉ ค่ำฉฉมัธยฐานตัวอย่าง มีไว้เพื่อหาจุดกึ่งกลางหรือค่ากลางของข้อมูลในกลุ่ฉฉตัวอย่าง การหาค่ำฉฉมัธยฐานตัวอย่างทำได้โดยนำข้อมูลมาเรียงลำดับจากน้อยไปมาก ค่ำฉฉมัธยฐานตัวอย่างก็คืฉฉข้อมูลที่อยูฉฉในตำแหน่งกึ่งกลางพอดี ค่ำฉฉมัธยฐานเป็นตัฉฉแบ่งข้อมูลออกเป็น 2 ส่วน ส่วนแรก (50%) จะมีค่าน้อยกวฉฉมัธยฐาน ส่วนที่สอง (50%) จะมีค่ามากกว่าหรือเท่ากับมัธยฐาน

ถ้าหากในกลุ่ฉฉตัวอย่างมีข้อมูล n ตัว ซึ่งเรียงจากน้อยไปมาก

- ถ้า n เป็นเลขคี่ ค่ำฉฉมัธยฐานตัวอย่างก็คืฉฉข้อมูลที่อยูฉฉในตำแหน่ง $\frac{n+1}{2}$
- ถ้า n เป็นเลขคู่ ค่ำฉฉมัธยฐานตัวอย่างก็คืฉฉค่าเฉลี่ยของข้อมูลที่อยูฉฉในตำแหน่ง $\frac{n}{2}$ กับข้อมูลที่อยูฉฉในตำแหน่ง $\frac{n}{2} + 1$

ตัวอย่าง 8.3 ข้อมูลตัวอย่างของน้ำหนักนักเรียนในหน่วยกิโลกรัมมีดังนี้ 45, 49, 55, 41, 62, 705 จงหาค่ำฉฉเฉลี่ยตัวอย่าง และค่ำฉฉมัธยฐานตัวอย่าง

วิธีทำ ค่ำฉฉเฉลี่ยตัวอย่างคืฉฉ

$$\bar{X} = \frac{45 + 49 + 55 + 41 + 62 + 705}{6} = 159.5$$

เมื่อเรียงลำดับข้อมูลจากน้อยไปมากจะได้ 41, 45, 49, 55, 62, 705 ข้อมูลชุดนี้มี 6 ตัวฉฉงนั้นค่ำฉฉมัธยฐานจะเป็นค่าเฉลี่ยของข้อมูลในตำแหน่งที่ 6/2 และ 6/2+1

ข้อมูลในตำแหน่งที่ 6/2 คือ 49

ข้อมูลในตำแหน่งที่ 6/2 + 1 คือ 55

ดังนั้นค่ามัธยฐานตัวอย่างคือ $(49+55)/2 = 52$

ปัญหา 8.14 ค่ามัธยฐานตัวอย่างจะเป็นประโยชน์มากในกรณีใด?

วิธีชนา ค่ามัธยฐานตัวอย่างจะเป็นประโยชน์มากในกรณีที่ข้อมูลในกลุ่มตัวอย่างมีข้อมูลผิดปกติอยู่ ดังเช่น ในตัวอย่าง 8.3 มีข้อมูล 705 ที่เป็นข้อมูลผิดปกติ เมื่อเราหาค่าเฉลี่ย ข้อมูลที่ผิดปกตินี้จะส่งผลให้ค่าเฉลี่ยสูงผิดปกติไปด้วย ทำให้เราตีความค่ากลางของข้อมูลคลาดเคลื่อนไปมาก แต่จะเห็นว่าค่ามัธยฐานตัวอย่างอยู่ที่ 52 ในกรณีนี้การใช้ค่ามัธยฐานตัวอย่างเป็นค่ากลางจึงดีกว่าการใช้ค่าเฉลี่ย เนื่องจากไม่ได้ถูกข้อมูลผิดปกติดึงให้คลาดเคลื่อนไป

ปัญหา 8.15 ฐานนิยมตัวอย่าง (Sample Mode) คืออะไร? หาอย่างไร?

วิธีชนา ฐานนิยมตัวอย่าง คือ ข้อมูลที่มีความถี่มากที่สุดในกลุ่มตัวอย่าง

ปัญหา 8.16 ควอร์ไทล์ (Quartile) คืออะไร? หาได้อย่างไร?

วิธีชนา ในทำนองเดียวกันกับการที่เราใช้มัธยฐานในการแบ่งข้อมูลออกเป็น 2 ครั้ง เราใช้ควอร์ไทล์แบ่งข้อมูลในกลุ่มตัวอย่างออกเป็น 4 ส่วน ซึ่งมีวิธีการหาได้ดังนี้

กำหนด n เป็นจำนวนข้อมูลในกลุ่มตัวอย่าง ให้เรียงลำดับข้อมูลจากน้อยไปหามาก ควอร์ไทล์ต่างๆ หาได้ดังนี้ (ดูรายละเอียดการคำนวณเพิ่มเติมได้ใน [4])

- **ควอร์ไทล์ที่ 1** หาได้โดยคำนวณค่าตำแหน่ง $0.25(n + 1)$ ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือควอร์ไทล์ที่ 1 แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านั้นเป็นควอร์ไทล์ที่ 1
- **ควอร์ไทล์ที่ 2** หาได้โดยคำนวณค่าตำแหน่ง $0.50(n + 1)$ ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือควอร์ไทล์ที่ 2 แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านั้นเป็นควอร์ไทล์ที่ 2 จะสังเกตได้ว่าควอร์ไทล์ที่ 2 ก็คือค่ามัธยฐานนั่นเอง
- **ควอร์ไทล์ที่ 3** หาได้โดยคำนวณค่าตำแหน่ง $0.75(n + 1)$ ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือควอร์ไทล์ที่ 3 แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านั้นเป็นควอร์ไทล์ที่ 3

ตัวอย่าง 8.4 จำนวนแต้มที่ทำได้ในแต่ละปีของนักบาสเก็ตบอล Michael Jordan เป็นไปดังตาราง 8.1 จงหาควอร์ไทล์ที่ 1, 2, และ 3 ของข้อมูลชุดนี้

ตาราง 8.1: จำนวนแต้มรวมในแต่ละปีของ Michael Jordan

ปี	จำนวนแต้ม
1984	2313
1985	408
1986	3014
1987	2868
1988	2633
1989	2753
1990	2580
1991	2404
1992	2541
1994	457
1995	2491
1996	2431
1997	2357
2001	2375
2002	1640

วิธีทำ เมื่อนำข้อมูลมาเรียงลำดับจากน้อยไปมากจะได้ดังนี้

408, 457, 1640, 2313, 2357, 2375, 2404, 2431, 2491, 2541, 2580, 2633, 2753, 2868, 3014

ข้อมูลนี้มีจำนวน $n = 15$

ตำแหน่งของควอร์ไทล์ที่ 1 คือ $0.25(15 + 1) = 4$ ค่าควอร์ไทล์ที่ 1 คือ 2313

ตำแหน่งของควอร์ไทล์ที่ 2 คือ $0.50(15 + 1) = 8$ ค่าควอร์ไทล์ที่ 2 คือ 2431

ตำแหน่งของควอร์ไทล์ที่ 3 คือ $0.75(15 + 1) = 12$ ค่าควอร์ไทล์ที่ 3 คือ 2633

ปัญหา 8.17 เปอร์เซ็นไทล์ (Percentile) คืออะไร? หาได้อย่างไร?

วิธีชนา เปอร์เซ็นไทล์แบ่งข้อมูลในกลุ่มตัวอย่างออกเป็น 100 ส่วน เปอร์เซ็นไทล์ที่ p จะแบ่งข้อมูลโดยที่จำนวน $p\%$ ของข้อมูลจะมีค่าอยู่ต่ำกว่าเปอร์เซ็นไทล์ที่ p และจำนวน $(100 - p)\%$ ของข้อมูลจะมีค่าอยู่สูงกว่าเปอร์เซ็นไทล์ที่ p

กำหนด n เป็นจำนวนข้อมูลในกลุ่มตัวอย่าง ให้เรียงลำดับข้อมูลจากน้อยไปหามาก เปอร์เซ็นไทล์ที่ p หาได้โดยคำนวณค่าตำแหน่ง $(p/100)(n + 1)$ ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือ

เปอร์เซ็นต์ไทล์ที่ p แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านั้นเป็นเปอร์เซ็นต์ไทล์ที่ p

ตัวอย่าง 8.5 จากข้อมูลในตัวอย่าง 8.4 จงหาเปอร์เซ็นต์ไทล์ที่ 20 และ เปอร์เซ็นต์ไทล์ที่ 80

วิธีทำ เมื่อนำข้อมูลมาเรียงลำดับจากน้อยไปมากจะได้ดังนี้

408, 457, 1640, 2313, 2357, 2375, 2404, 2431, 2491, 2541, 2580, 2633, 2753, 2868, 3014

ข้อมูลนี้มีจำนวน $n = 15$

ตำแหน่งของเปอร์เซ็นต์ไทล์ที่ 20 คือ $0.20(15+1) = 3.2$ ดังนั้นนำค่าเฉลี่ยของข้อมูลในตำแหน่งที่ 3 และ 4 มาใช้ ซึ่งก็คือ $(1640 + 2313)/2 = 1976.5$ สรุปเปอร์เซ็นต์ไทล์ที่ 20 คือ 1976.5

ตำแหน่งของเปอร์เซ็นต์ไทล์ที่ 80 คือ $0.80(15 + 1) = 12.8$ ดังนั้นนำค่าเฉลี่ยของข้อมูลในตำแหน่งที่ 12 และ 13 มาใช้ ซึ่งก็คือ $(2633 + 2753)/2 = 2693$ สรุปเปอร์เซ็นต์ไทล์ที่ 80 คือ 2693

8.3 ข้อมูลสรุปเชิงภาพ (Graphical Summaries)


ข้อมูลสรุปเชิงภาพเป็นเครื่องมือสำคัญในการมองภาพรวมของข้อมูล (Visualize) ว่าข้อมูลนั้นโดยรวมมีลักษณะอย่างไร การใช้ข้อมูลสรุปเชิงภาพได้อย่างมีประสิทธิภาพ จะช่วยให้เราเข้าใจและสามารถวิเคราะห์ข้อมูลนั้นได้อย่างมีประสิทธิภาพ ซึ่งข้อมูลสรุปเชิงภาพนั้นก็มีย่อยแบบ เราจำเป็นต้องเลือกใช้ให้ถูกต้องตามความเหมาะสม ในส่วนนี้เราจะดูว่าข้อมูลสรุปเชิงภาพที่ใช้กันบ่อยๆมีอะไรบ้าง

ปูจฉฉ 8.18 ด็อตพล็อต (Dotplot) คืออะไร มีลักษณะอย่างไร?


วิธีฉฉฉ ด็อตพล็อต (Dotplot) คือ แผนภาพที่ใชัแสดงควมถี่ของค่าต่างๆ ในกลุ่มตัวอย่าง รูป 8.1 แสดงตัวอย่างของด็อตพล็อต จากรูปจะสังเกตได้วฉฉในข้อมูลชุดนี้มีรถที่วิ่งด้วยควมเร็ว 15 เมตร/วินาที จำนวน 3 คัน (3 จุด) และ มีรถที่วิ่งด้วยควมเร็ว 20 เมตร/วินาที จำนวน 5 คัน (5 จุด) เป็นต้น

ปูจฉฉ 8.19 ฮิสโทแกรม (Histogram) คืออะไร มีลักษณะอย่างไร?

วิธีฉฉฉ ฮิสโทแกรม (Histogram) คือ กราฟแห่งแสดงควมถี่ (Frequency) หรือควมถี่สัมพันธ์ (Relative Frequency) ของข้อมูลโดยที่มีกรจำแนกข้อมูลออกเป็นออกเป็นระดับชั้น (Class) รูป 8.2 แสดงตัวอย่างของฮิสโทแกรมของข้อมูลอุณหภูมิในนัวยอร์คตั้งแต่เดือนพฤษภคมถึงกันยายน ค.ศ. 1973 จากรูปจะเห็นได้วฉฉบนแกนอนมีการแบ่งข้อมูลออกเป็นระดับชั้นต่างๆ เช่น ชั้นที่มีอุณหภูมิในช่วง 71-75 F, ชั้น

Dotplot of Vehicle Speed

รูป 8.1: ตัวอย่างของดอตพล็อต (Dotplot)

Histogram of Temperature

รูป 8.2: ตัวอย่างของฮิสโตแกรม (Histogram) แสดงการกระจายของอุณหภูมิในนิวยอร์กตั้งแต่เดือนพฤษภาคมถึงกันยายน ค.ศ. 1973

ที่มีอุณหภูมิในช่วง 76-80 F เป็นต้น บนแกนตั้งจะบอกค่าความถี่สัมพัทธ์ของข้อมูลในชั้นต่างๆ เช่น อุณหภูมิในช่วง 56-60 F มีความถี่คิดเป็นสัดส่วน 0.05 ของข้อมูลทั้งหมด

ปูจจา 8.20 ความหนาแน่น (Density) คืออะไร?

วิธีชนา บ่อยครั้งที่เราอาจเห็นบนแกนตั้งของฮิสโทแกรมแสดงผลสิ่งที่เรียกว่า “ความหนาแน่น (Density)” แทนที่จะเป็นความถี่สัมพัทธ์ ซึ่งความหนาแน่นนี้สัมพันธ์กับความถี่สัมพัทธ์และความกว้างของชั้น (Class width) ดังนี้

$$\text{Density} = \text{Relative Frequency} / \text{Class Width}$$


กล่าวคือ ความหนาแน่นของแต่ละชั้นข้อมูลหาได้จากอัตราส่วนระหว่างความถี่สัมพัทธ์และความกว้างของชั้นข้อมูลนั้น เช่น ในรูป 8.2 อุณหภูมิในช่วง 56-60 F จะมีความหนาแน่นเท่ากับ $0.05/5 = 0.01$ โดยที่ 0.05 คือความถี่สัมพัทธ์ของชั้นข้อมูลนี้และ 5 คือความกว้างของชั้นข้อมูลนี้ (56-60)

ปูจจา 8.21 บ็อกซ์พล็อต (Boxplot) คืออะไร หาอย่างไร?

วิธีชนา บ็อกซ์พล็อต (Box Plot) เป็นแผนภูมิที่ใช้แสดงควอร์ไทล์ที่ 1, 2, และ 3 ของข้อมูล รวมถึงระยะห่างระหว่างควอร์ไทล์ที่ 1 และ 3 ซึ่งเรียกว่า Interquartile Range (IQR) ส่วนประกอบที่สำคัญของบ็อกซ์พล็อตเป็นไปดังรูป 8.3 ซึ่งอธิบายได้ดังนี้

- เส้นแนวขวางที่อยู่ส่วนกลางกล่องระบุค่ามัธยฐาน
- เส้นแนวขวางขอบล่างของกล่องระบุควอร์ไทล์ที่ 1
- เส้นแนวขวางขอบล่างบนกล่องระบุควอร์ไทล์ที่ 3
- เส้นแนวตั้งด้านบนของกล่อง (Whisker) ระบุค่าสูงสุดในข้อมูลที่ยังอยู่ภายใน 1.5IQR นับจากควอร์ไทล์ที่ 3
- เส้นแนวตั้งด้านล่างของกล่อง (Whisker) ระบุค่าต่ำสุดในข้อมูลที่ยังอยู่ภายใน 1.5IQR นับจากควอร์ไทล์ที่ 1
- กากบาทคือข้อมูลที่เป็นข้อมูลผิดปกติ (Outliers) ซึ่งมีความมากกว่า 1.5IQR นับจากควอร์ไทล์ที่ 3 และน้อยกว่า 1.5IQR นับจากควอร์ไทล์ที่ 1

บ็อกซ์พล็อตช่วยให้เราเห็นว่าข้อมูลในควอร์ไทล์ใดมีการกระจุกตัวหรือกระจายตัว เช่น ในรูป 8.3 เราสังเกตได้ว่า ระยะห่างระหว่างมัธยฐานกับควอร์ไทล์ที่ 3 นั้นสั้นกว่าระยะห่างระหว่างมัธยฐานกับควอร์




รูป 8.3: ส่วนประกอบต่างๆ ของบ็อกซ์พล็อต

ไทล์ที่ 1 เป็นการบ่งบอกว่าข้อมูลมีการกระจุกตัวในช่วงระหว่างมัธยฐานกับควอร์ไทล์ที่ 3 แต่ข้อมูลมีการกระจายตัวมากขึ้นในช่วงระหว่างมัธยฐานกับควอร์ไทล์ที่ 1

เราสามารถแสดงบ็อกซ์พล็อตของข้อมูลที่แบ่งตามประเภทหลายๆประเภทพร้อมกันได้ ตัวอย่างดังเช่นที่แสดงในรูป 8.4 ตัวอย่างบ็อกซ์พล็อตนี้แสดงความยาวของกลีบดอกไอริสแยกตามสายพันธุ์ จากตัวอย่างนี้จะเห็นว่าโดยทั่วไปแล้วความยาวกลีบดอกของสายพันธุ์ Setosa จะสั้นที่สุดในบรรดา 3 สายพันธุ์ ซึ่งอยู่ในช่วงประมาณ 1-2 ซม. ความยาวกลีบดอกของสายพันธุ์ Setosa มีการกระจายตัวค่อนข้างสมมาตรกัน และมีข้อมูลผิดปกติอยู่ 1 ตัว มีค่ามัธยฐานอยู่ที่ประมาณ 1.5 ซม. แต่ในส่วนของสายพันธุ์ Virginica ความยาวของกลีบดอกมีการกระจายตัวมากในช่วงระหว่างควอร์ไทล์ที่ 1 กับมัธยฐาน และมีการกระจุกตัวมากขึ้นในช่วงระหว่างมัธยฐานกับควอร์ไทล์ที่ 3 ในกรณีของสายพันธุ์ Virginica นี้ไม่มีข้อมูลผิดปกติ มีค่ามัธยฐานอยู่ที่ประมาณ 5.5 ซม.

นอกจากนี้ยังสังเกตได้อีกว่าความสูงของกล่องของสายพันธุ์ Virginica มีมากกว่าของสายพันธุ์ Setosa ซึ่งบ่งชี้ว่าความยาวกลีบดอกของสายพันธุ์ Virginica มีการกระจายตัวมากกว่าเมื่อเทียบกับสายพันธุ์ Setosa



รูป 8.4: ตัวอย่างบ็อกซ์พล็อตแสดงความยาวของกลีบดอกไอริสแยกตามสายพันธุ์

บรรณานุกรม

- [1] S. Ross, *A First Course in Probability*, 9th ed. Pearson, 2012.
- [2] D. P. Bertsekas and J. N. Tsitsiklis, *Introduction to Probability*, 2nd ed. Athena Scientific, 2008.
- [3] A. Leon-Garcia, *Probability, Statistics, and Random Processes for Electrical Engineering*, 3rd ed. Pearson, 2008.
- [4] W. Navidi, *Statistics for Engineers and Scientists*, 3rd ed. McGraw-Hill, 2010.