



Lecture Notes

ความน่าจะเป็นและสถิติ

Probability and Statistics

ศาสตราจารย์ ดร. สุขสันต์ พาณิชพาพิบูล

คณะเทคโนโลยีสารสนเทศ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

# สถิติเบื้องต้น (Basic Statistics)

- หลักแนวคิดของสถิติ
- สถิติสรุป (Summary Statistics)
- ข้อมูลสรุปเชิงภาพ (Graphical Summaries)

**ปฏิจา 8.1** หลักแนวคิดของสถิติคืออะไร เราเรียนสถิติไปเพื่ออะไร?

การเรียนรู้หลักวิชาการทางสถิติจะช่วยให้เรามีเครื่องมือในการหาคำตอบเกี่ยวกับประชากร (ซึ่งอาจจะมีจำนวนมาก) โดยใช้กลุ่มตัวอย่าง (ซึ่งมีจำนวนน้อย) ได้

93

### ปูจฉฉ 8.2 ประชากร (Population) คืฉฉอะไร?

วิธีฉฉฉฉฉ **ประชากร** คืฉฉ **ผลการทดลองทั้งหมดเกี่ยวกับข้อมูลที่เราต้องการหา** เช่น เราอาจต้องการทราบความสูงของประชากรในประเทศไทย ประชากรในกรณีนี้ก็คือความสูงของคนไทยทั่วประเทศ (70 ล้านคน)

### ปูจฉฉ 8.3 กลุ่มตัวอย่าง (Sample) คืฉฉอะไร?

วิธีฉฉฉฉฉ **กลุ่มตัวอย่าง** คืฉฉ สุ่มสุ่มของประชากร ซึ่งเป็น**ผลการทดลองที่เราสังเกตหรือได้มา** เช่น ความสูงของคนไทยที่สุ่มเลือกมาเป็นกลุ่มตัวอย่าง

### ปูจฉฉ 8.4 การสุ่ม (Sampling) คืฉฉอะไร?

วิธีฉฉฉฉฉ **การสุ่ม (Sampling)** คืฉฉ **การเลือกกลุ่มตัวอย่างบางส่วนออกมาจากประชากรทั้งหมด**

### ปูจฉฉ 8.5 การสุ่มอย่างง่าย (Simple Random Sampling) คืฉฉอะไร?

วิธีฉฉฉฉฉ **การสุ่มอย่างง่าย (Simple Random Sampling)** คืฉฉ การสุ่มเลือกที่โอกาสจะได้ตัวอย่างใดๆจาก**ประชากรทั้งหมด** มีโอกาสเกิดขึ้นได้เท่าๆกัน คล้ายๆกับการจับฉลากอย่างง่ายๆ นั่นเอง

## 8.2 สถิติสรุป (Summary Statistics)

โดยมากแล้วข้อมูลที่เราต้องการหาคำตอบหรือนำมาวิเคราะห์นั้นจะประกอบไปด้วยข้อมูลจำนวนมาก ซึ่งบางทียากต่อการทำความเข้าใจเบื้องต้น ดังนั้นจึงมีการคิดสิ่งๆที่เรียกว่าสถิติสรุปขึ้นมาเพื่อใช้บอกลักษณะคร่าวๆ โดยสรุปของข้อมูล สถิติสรุปที่นิยมใช้กัน เช่น **ค่าเฉลี่ย ค่ามัธยฐาน ค่าเบี่ยงเบนมาตรฐาน**

### ปูจฉฉ 8.6 ข้อมูล (Data) แบ่งออกหลักๆ ได้กี่ชนิด ฉฉฉบ้าง?

วิธีฉฉฉฉฉ ข้อมูล แบ่งออกหลักๆ ได้เป็น 2 ชนิด ดังนี้

1. **ข้อมูลเชิงปริมาณ (Quantitative Data)** หรือ**ข้อมูลที่เป็นตัวเลข (Numerical Data)** เช่น ความสูงของนักเรียน อุณหภูมิ จำนวนผู้เข้าชมเว็บไซต์ในหนึ่งวัน
2. **ข้อมูลเชิงคุณภาพ (Qualitative Data)** หรือข้อมูลที่เป็น**การแบ่งประเภท (Categorical Data)** ซึ่งยังแยกย่อยได้เป็น 2 ชนิดคือ
  - ชนิด**ไม่มีความสัมพันธ์เชิงลำดับ** เช่น เพศ (ชาย, หญิง) กลุ่มเลือด (AB, A, B, O)

- ชนิดมีความสัมพันธ์เชิงลำดับ เช่น ระดับการศึกษา (อนุบาล, ประถม, มัธยม) จะเห็นว่ามีความสัมพันธ์เชิงลำดับกล่าวคือ มัธยมมีระดับสูงกว่าประถม หรือขนาดเสื้อ (S, M, L, XL) จะเห็นว่าขนาด XL ใหญ่กว่าขนาด M เป็นต้น

### ปูจจา 8.7 ค่าเฉลี่ยตัวอย่าง (Sample Mean) คืออะไร หาอย่างไร?

วิธีชนา ค่าเฉลี่ยตัวอย่าง คือ ค่าเฉลี่ยของข้อมูลที่อยู่ในกลุ่มตัวอย่าง บางทีอาจเรียกว่าค่าเฉลี่ยเลขคณิต (Arithmetic Mean) ก็ได้ ซึ่งมีวิธีการหาดังนี้

กำหนด  $X_1, X_2, \dots, X_n$  เป็นข้อมูลในกลุ่มตัวอย่าง ค่าเฉลี่ยตัวอย่างหาได้ดังนี้

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

ตัวอย่าง 8.1 นักเรียน 5 คนในโรงเรียนถูกสุ่มมาเป็นกลุ่มตัวอย่าง นักเรียนแต่ละคนมีน้ำหนักในหน่วยกิโลกรัมดังนี้ 45, 49, 55, 41, 62 จงหาค่าเฉลี่ยตัวอย่างของน้ำหนักนักเรียน

วิธีทำ หาได้ดังนี้

$$\begin{aligned} \bar{X} &= \frac{1}{5} \times (45 + 49 + 55 + 41 + 62) \\ &= 50.4 \end{aligned}$$

### ปูจจา 8.8 ค่าความแปรปรวนตัวอย่าง (Sample Variance) คืออะไร หาอย่างไร?

วิธีชนา ค่าความแปรปรวนตัวอย่าง คือ ค่าตรรกะที่ใช้วัดการกระจายตัวของข้อมูลในกลุ่มตัวอย่าง ซึ่งหาได้ดังนี้

กำหนด  $X_1, X_2, \dots, X_n$  เป็นข้อมูลในกลุ่มตัวอย่าง ค่าความแปรปรวนตัวอย่างหาได้ดังนี้

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

หรืออาจหาตามสมการนี้ก็ได้เช่นกัน

$$s^2 = \frac{1}{n-1} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

### ปูจจา 8.9 ค่าเบี่ยงเบนมาตรฐานตัวอย่าง (Sample Standard Deviation) คืออะไร หาอย่างไร?

**วิธีชนา** ค่าเบี่ยงเบนมาตรฐานตัวอย่าง คือ รากที่สองของค่าความแปรปรวนตัวอย่าง ซึ่งหาได้ดังนี้  
กำหนด  $X_1, X_2, \dots, X_n$  เป็นข้อมูลในกลุ่มตัวอย่าง ค่าเบี่ยงเบนมาตรฐานตัวอย่างหาได้ดังนี้

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

หรืออาจหาตามสมการนี้ก็ได้เช่นกัน

$$s = \sqrt{\frac{1}{n-1} \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)}$$

**ปูจจา 8.10** ทำไมเวลาคำนวณหา  $s^2$  กับ  $s$  ต้องหารด้วย  $n-1$  แทนที่จะหารด้วย  $n$ ?

**วิธีชนา** เวลาคำนวณหา  $s^2$  เราได้ใช้ค่าเฉลี่ยตัวอย่าง  $\bar{X}$  แทนที่จะใช้ค่าเฉลี่ยที่แท้จริงของประชากร โดยปกติแล้ว ความเบี่ยงเบนจากค่าเฉลี่ยตัวอย่างมักจะน้อยกว่าความเบี่ยงเบนจากค่าเฉลี่ยที่แท้จริงของประชากร การหารด้วย  $n-1$  แทนที่จะหารด้วย  $n$  ช่วยมาแก้ไขการคำนวณตรงนี้ให้ถูกต้อง

**ตัวอย่าง 8.2** จากตัวอย่าง 8.1 จงหาค่าความแปรปรวนตัวอย่าง และค่าเบี่ยงเบนมาตรฐานตัวอย่าง

**วิธีทำ** หาค่าความแปรปรวนตัวอย่างได้ดังนี้

$$\begin{aligned} s^2 &= \frac{1}{4} ((45 - 50.4)^2 + (49 - 50.4)^2 + (55 - 50.4)^2 + (41 - 50.4)^2 + (62 - 50.4)^2) \\ &= \frac{275.2}{4} \\ &= 68.8 \end{aligned}$$

ค่าเบี่ยงเบนมาตรฐานตัวอย่าง  $s = \sqrt{68.8} = 8.2946$

**ปูจจา 8.11** การคูณและบวกข้อมูลในกลุ่มตัวอย่างด้วยค่าคงที่ ส่งผลอย่างไรต่อค่าเฉลี่ยตัวอย่างและค่าความแปรปรวนตัวอย่าง?

**วิธีชนา** ส่งผลดังนี้

กำหนด  $X_1, X_2, \dots, X_n$  เป็นข้อมูลในกลุ่มตัวอย่าง และ  $Y_i = aX_i + b$  โดยที่  $a, b$  เป็นค่าคงที่ ค่าเฉลี่ยเปลี่ยนไปดังนี้คือ

$$\bar{Y} = a\bar{X} + b$$



ข้อมูลในตำแหน่งที่ 6/2 คือ 49

ข้อมูลในตำแหน่งที่ 6/2 + 1 คือ 55

ดังนั้นค่ามัธยฐานตัวอย่างคือ  $(49+55)/2 = 52$

#### ปัญหา 8.14 ค่ามัธยฐานตัวอย่างจะเป็นประโยชน์มากในกรณีใด?

วิธีชนา ค่ามัธยฐานตัวอย่างจะเป็นประโยชน์มากในกรณีที่ข้อมูลในกลุ่มตัวอย่างมีข้อมูลผิดปกติอยู่ ดังเช่น ในตัวอย่าง 8.3 มีข้อมูล 705 ที่เป็นข้อมูลผิดปกติ เมื่อเราหาค่าเฉลี่ย ข้อมูลที่ผิดปกตินี้จะส่งผลให้ค่าเฉลี่ยสูงผิดปกติไปด้วย ทำให้เราตีความค่ากลางของข้อมูลคลาดเคลื่อนไปมาก แต่จะเห็นว่าค่ามัธยฐานตัวอย่างอยู่ที่ 52 ในกรณีนี้การใช้ค่ามัธยฐานตัวอย่างเป็นค่ากลางจึงดีกว่าการใช้ค่าเฉลี่ย เนื่องจากไม่ได้ถูกข้อมูลผิดปกติดึงให้คลาดเคลื่อนไป

↳ Outlier

#### ปัญหา 8.15 ฐานนิยมตัวอย่าง (Sample Mode) คืออะไร? หาอย่างไร?

วิธีชนา ฐานนิยมตัวอย่าง คือ ข้อมูลที่มีความถี่มากที่สุดในกลุ่มตัวอย่าง

↳ รั้งอันดับสูงสุด

#### ปัญหา 8.16 ควอร์ไทล์ (Quartile) คืออะไร? หาได้อย่างไร?

วิธีชนา ในทำนองเดียวกันกับการที่เราใช้มัธยฐานในการแบ่งข้อมูลออกเป็น 2 ครั้ง เราใช้ควอร์ไทล์แบ่งข้อมูลในกลุ่มตัวอย่างออกเป็น 4 ส่วน ซึ่งมีวิธีการหาได้ดังนี้

กำหนด  $n$  เป็นจำนวนข้อมูลในกลุ่มตัวอย่าง ให้เรียงลำดับข้อมูลจากน้อยไปหามาก ควอร์ไทล์ต่างๆ หาได้ดังนี้ (ดูรายละเอียดการคำนวณเพิ่มเติมได้ใน [4])

- **ควอร์ไทล์ที่ 1** หาได้โดยคำนวณค่าตำแหน่ง  $0.25(n + 1)$  ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือควอร์ไทล์ที่ 1 แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านั้นเป็นควอร์ไทล์ที่ 1
- **ควอร์ไทล์ที่ 2** หาได้โดยคำนวณค่าตำแหน่ง  $0.50(n + 1)$  ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือควอร์ไทล์ที่ 2 แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านั้นเป็นควอร์ไทล์ที่ 2 จะสังเกตได้ว่าควอร์ไทล์ที่ 2 ก็คือค่ามัธยฐานนั่นเอง
- **ควอร์ไทล์ที่ 3** หาได้โดยคำนวณค่าตำแหน่ง  $0.75(n + 1)$  ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือควอร์ไทล์ที่ 3 แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านั้นเป็นควอร์ไทล์ที่ 3

**ตัวอย่าง 8.4** จำนวนแต้มที่ทำได้ในแต่ละปีของนักบาสเก็ตบอล Michael Jordan เป็นไปดังตาราง 8.1 จงหาควอร์ไทล์ที่ 1, 2, และ 3 ของข้อมูลชุดนี้

ตาราง 8.1: จำนวนแต้มรวมในแต่ละปีของ Michael Jordan

| ปี   | จำนวนแต้ม |
|------|-----------|
| 1984 | 2313      |
| 1985 | 408       |
| 1986 | 3014      |
| 1987 | 2868      |
| 1988 | 2633      |
| 1989 | 2753      |
| 1990 | 2580      |
| 1991 | 2404      |
| 1992 | 2541      |
| 1994 | 457       |
| 1995 | 2491      |
| 1996 | 2431      |
| 1997 | 2357      |
| 2001 | 2375      |
| 2002 | 1640      |

**วิธีทำ** เมื่อนำข้อมูลมาเรียงลำดับจากน้อยไปมากจะได้ดังนี้

408, 457, 1640, 2313, 2357, 2375, 2404, 2431, 2491, 2541, 2580, 2633, 2753, 2868, 3014

ข้อมูลนี้มีจำนวน  $n = 15$

ตำแหน่งของควอร์ไทล์ที่ 1 คือ  $0.25(15 + 1) = 4$  ค่าควอร์ไทล์ที่ 1 คือ 2313

ตำแหน่งของควอร์ไทล์ที่ 2 คือ  $0.50(15 + 1) = 8$  ค่าควอร์ไทล์ที่ 2 คือ 2431

ตำแหน่งของควอร์ไทล์ที่ 3 คือ  $0.75(15 + 1) = 12$  ค่าควอร์ไทล์ที่ 3 คือ 2633

**ปัญหา 8.17** เปอร์เซ็นไทล์ (Percentile) คืออะไร? หาได้อย่างไร?

**วิธีзна** เปอร์เซ็นไทล์แบ่งข้อมูลในกลุ่มตัวอย่างออกเป็น 100 ส่วน เปอร์เซ็นไทล์ที่  $p$  จะแบ่งข้อมูลโดยที่จำนวน  $p\%$  ของข้อมูลจะมีค่าอยู่ต่ำกว่าเปอร์เซ็นไทล์ที่  $p$  และจำนวน  $(100 - p)\%$  ของข้อมูลจะมีค่าอยู่สูงกว่าเปอร์เซ็นไทล์ที่  $p$

กำหนด  $n$  เป็นจำนวนข้อมูลในกลุ่มตัวอย่าง ให้เรียงลำดับข้อมูลจากน้อยไปหามาก เปอร์เซ็นไทล์ที่  $p$  หาได้โดยคำนวณค่าตำแหน่ง  $(p/100)(n + 1)$  ถ้าค่าตำแหน่งนี้เป็นจำนวนเต็ม ข้อมูลที่อยู่ในตำแหน่งนี้คือ

เปอร์เซ็นต์ไทล์ที่  $p$  แต่ถ้าค่าตำแหน่งนี้ไม่ใช่จำนวนเต็มให้หาค่าเฉลี่ยของข้อมูลที่อยู่ด้านซ้ายและขวาของตำแหน่งที่คำนวณได้และใช้ค่านี้เป็นเปอร์เซ็นต์ไทล์ที่  $p$

**ตัวอย่าง 8.5** จากข้อมูลในตัวอย่าง 8.4 จงหาเปอร์เซ็นต์ไทล์ที่ 20 และ เปอร์เซ็นต์ไทล์ที่ 80

**วิธีทำ** เมื่อนำข้อมูลมาเรียงลำดับจากน้อยไปมากจะได้ดังนี้

408, 457, 1640, 2313, 2357, 2375, 2404, 2431, 2491, 2541, 2580, 2633, 2753, 2868, 3014

ข้อมูลนี้มีจำนวน  $n = 15$

ตำแหน่งของเปอร์เซ็นต์ไทล์ที่ 20 คือ  $0.20(15+1) = 3.2$  ดังนั้นนำค่าเฉลี่ยของข้อมูลในตำแหน่งที่ 3 และ 4 มาใช้ ซึ่งก็คือ  $(1640 + 2313)/2 = 1976.5$  สรุปเปอร์เซ็นต์ไทล์ที่ 20 คือ 1976.5

ตำแหน่งของเปอร์เซ็นต์ไทล์ที่ 80 คือ  $0.80(15+1) = 12.8$  ดังนั้นนำค่าเฉลี่ยของข้อมูลในตำแหน่งที่ 12 และ 13 มาใช้ ซึ่งก็คือ  $(2633 + 2753)/2 = 2693$  สรุปเปอร์เซ็นต์ไทล์ที่ 80 คือ 2693

## 8.3 ข้อมูลสรุปเชิงภาพ (Graphical Summaries)

ข้อมูลสรุปเชิงภาพเป็นเครื่องมือสำคัญในการมองภาพรวมของข้อมูล (Visualize) ว่าข้อมูลนั้นโดยรวมมีลักษณะอย่างไร การใช้ข้อมูลสรุปเชิงภาพได้อย่างมีประสิทธิภาพ จะช่วยให้เราเข้าใจและสามารถวิเคราะห์ข้อมูลนั้นได้อย่างมีประสิทธิภาพ ซึ่งข้อมูลสรุปเชิงภาพนั้นก็มีย่อยแบบ เราจำเป็นต้องเลือกใช้ให้ถูกต้องตามความเหมาะสม ในส่วนนี้เราจะดูว่าข้อมูลสรุปเชิงภาพที่ใช้กันบ่อยๆมีอะไรบ้าง


**ปูจฉฉ 8.18** **ด็อทพล็อท (Dotplot)** คืออะไร มีลักษณะอย่างไร?

**วิธีฉฉฉฉ** ด็อทพล็อท (Dotplot) คือ **แผนภาพที่ใชัแสดงควมถี่ของค่าต่างๆ** ในกลุ่มตัวอย่าง รูป 8.1 แสดงตัวอย่างของด็อทพล็อท จากรูปจะสังเกตได้วฉฉฉในข้อมูลชุดนี้มีรถที่วิ่งด้วยควมเร็ว 15 เมตร/วินาที จำนวน 3 คัน (3 จุด) และ มีรถที่วิ่งด้วยควมเร็ว 20 เมตร/วินาที จำนวน 5 คัน (5 จุด) เป็นต้น

**ปูจฉฉ 8.19** **ฮิสโทแกรม (Histogram)** คืออะไร มีลักษณะอย่างไร?


**วิธีฉฉฉฉ** ฮิสโทแกรม (Histogram) คือ **กราฟแห่งแสดงควมถี่ (Frequency) หรือควมถี่สัมพัทธ์ (Relative Frequency)** ของข้อมูลโดยที่มีการจำแนกข้อมูลออกเป็นอกเป็นระดับชั้น (Class) รูป 8.2 แสดงตัวอย่างของฮิสโทแกรมของข้อมูลอุณหภูมิในนียอร์คตั้งแตเดือนพฤษภาคมถึงกันยายน ค.ศ. 1973 จากรูปจะเห็นได้วฉฉฉบนแกนอนมีการแบ่งข้อมูลออกเป็นระดับชั้นต่างๆ เช่น ชั้นที่มีอุณหภูมิในช่วง 71-75 F, ชั้น

### Dotplot of Vehicle Speed



รูป 8.1: ตัวอย่างของดอตพล็อต (Dotplot)

### Histogram of Temperature



รูป 8.2: ตัวอย่างของฮิสโตแกรม (Histogram) แสดงการกระจายของอุณหภูมิในนิวยอร์กตั้งแต่เดือนพฤษภาคมถึงกันยายน ค.ศ. 1973

ที่มีอุณหภูมิในช่วง 76-80 F เป็นต้น บนแกนตั้งจะบอกค่าความถี่สัมพัทธ์ของข้อมูลในชั้นต่างๆ เช่น อุณหภูมิ ในช่วง 56-60 F มีความถี่คิดเป็นสัดส่วน 0.05 ของข้อมูลทั้งหมด

### ปูจจา 8.20 ความหนาแน่น (Density) คืออะไร?

วิธีชันหา บ่อยครั้งที่เราอาจเห็นบนแกนตั้งของฮิสโทแกรมแสดงผลสิ่งที่เรียกว่า “ความหนาแน่น (Density)” แทนที่จะเป็นความถี่สัมพัทธ์ ซึ่งความหนาแน่นนี้สัมพันธ์กับความถี่สัมพัทธ์และความกว้างของชั้น (Class width) ดังนี้

$$\text{Density} = \text{Relative Frequency} / \text{Class Width}$$


กล่าวคือ ความหนาแน่นของแต่ละชั้นข้อมูลหาได้จากอัตราส่วนระหว่างความถี่สัมพัทธ์และความกว้างของชั้นข้อมูลนั้น เช่น ในรูป 8.2 อุณหภูมิในช่วง 56-60 F จะมีความหนาแน่นเท่ากับ  $0.05/5 = 0.01$  โดยที่ 0.05 คือความถี่สัมพัทธ์ของชั้นข้อมูลนี้และ 5 คือความกว้างของชั้นข้อมูลนี้ (56-60)

### ปูจจา 8.21 บ็อกซ์พล็อต (Boxplot) คืออะไร หาอย่างไร?

วิธีชันหา บ็อกซ์พล็อต (Box Plot) เป็นแผนภูมิที่ใช้แสดงควอร์ไทล์ที่ 1, 2, และ 3 ของข้อมูล รวมถึงระยะห่างระหว่างควอร์ไทล์ที่ 1 และ 3 ซึ่งเรียกว่า Interquartile Range (IQR) ส่วนประกอบที่สำคัญของบ็อกซ์พล็อตเป็นไปดังรูป 8.3 ซึ่งอธิบายได้ดังนี้

- เส้นแนวขวางที่อยู่ส่วนกลางกล่องระบุค่ามัธยฐาน
- เส้นแนวขวางขอบล่างของกล่องระบุควอร์ไทล์ที่ 1
- เส้นแนวขวางขอบบนกล่องระบุควอร์ไทล์ที่ 3
- เส้นแนวตั้งด้านบนของกล่อง (Whisker) ระบุค่าสูงสุดในข้อมูลที่ยังอยู่ภายใน 1.5IQR นับจากควอร์ไทล์ที่ 3
- เส้นแนวตั้งด้านล่างของกล่อง (Whisker) ระบุค่าต่ำสุดในข้อมูลที่ยังอยู่ภายใน 1.5IQR นับจากควอร์ไทล์ที่ 1
- กากบาทคือข้อมูลที่เป็นข้อมูลผิดปกติ (Outliers) ซึ่งมีความมากกว่า 1.5IQR นับจากควอร์ไทล์ที่ 3 และน้อยกว่า 1.5IQR นับจากควอร์ไทล์ที่ 1

บ็อกซ์พล็อตช่วยให้เราเห็นว่าข้อมูลในควอร์ไทล์ใดมีการกระจุกตัวหรือกระจายตัว เช่น ในรูป 8.3 เราสังเกตได้ว่า ระยะห่างระหว่างมัธยฐานกับควอร์ไทล์ที่ 3 นั้นสั้นกว่าระยะห่างระหว่างมัธยฐานกับควอร์




รูป 8.3: ส่วนประกอบต่างๆ ของบ็อกซ์พล็อต

ไทล์ที่ 1 เป็นการบ่งบอกว่าข้อมูลมีการกระจุกตัวในช่วงระหว่างมัธยฐานกับควอร์ไทล์ที่ 3 แต่ข้อมูลมีการกระจายตัวมากขึ้นในช่วงระหว่างมัธยฐานกับควอร์ไทล์ที่ 1

เราสามารถแสดงบ็อกซ์พล็อตของข้อมูลที่แบ่งตามประเภทหลายๆประเภทพร้อมกันได้ ตัวอย่างดังเช่นที่แสดงในรูป 8.4 ตัวอย่างบ็อกซ์พล็อตนี้แสดงความยาวของกลีบดอกไอริสแยกตามสายพันธุ์ จากตัวอย่างนี้จะเห็นว่าโดยทั่วไปแล้วความยาวกลีบดอกของสายพันธุ์ Setosa จะสั้นที่สุดในบรรดา 3 สายพันธุ์ ซึ่งอยู่ในช่วงประมาณ 1-2 ซม. ความยาวกลีบดอกของสายพันธุ์ Setosa มีการกระจายตัวค่อนข้างสมมาตรกัน และมีข้อมูลผิดปกติอยู่ 1 ตัว มีค่ามัธยฐานอยู่ที่ประมาณ 1.5 ซม. แต่ในส่วนของสายพันธุ์ Virginica ความยาวของกลีบดอกมีการกระจายตัวมากในช่วงระหว่างควอร์ไทล์ที่ 1 กับมัธยฐาน และมีการกระจุกตัวมากขึ้นในช่วงระหว่างมัธยฐานกับควอร์ไทล์ที่ 3 ในกรณีของสายพันธุ์ Virginica นี้ไม่มีข้อมูลผิดปกติ มีค่ามัธยฐานอยู่ที่ประมาณ 5.5 ซม.

นอกจากนี้ยังสังเกตได้อีกว่าความสูงของกล่องของสายพันธุ์ Virginica มีมากกว่าของสายพันธุ์ Setosa ซึ่งบ่งชี้ว่าความยาวกลีบดอกของสายพันธุ์ Virginica มีการกระจายตัวมากกว่าเมื่อเทียบกับสายพันธุ์ Setosa



รูป 8.4: ตัวอย่างบ็อกซ์พล็อตแสดงความยาวของกลีบดอกไอริสแยกตามสายพันธุ์

## บรรณานุกรม

- [1] S. Ross, *A First Course in Probability*, 9th ed. Pearson, 2012.
- [2] D. P. Bertsekas and J. N. Tsitsiklis, *Introduction to Probability*, 2nd ed. Athena Scientific, 2008.
- [3] A. Leon-Garcia, *Probability, Statistics, and Random Processes for Electrical Engineering*, 3rd ed. Pearson, 2008.
- [4] W. Navidi, *Statistics for Engineers and Scientists*, 3rd ed. McGraw-Hill, 2010.