



Lecture Notes

ความน่าจะเป็นและสถิติ

Probability and Statistics

ศาสตราจารย์ ดร. สุขสันต์ พาณิชพาพิบูล

คณะเทคโนโลยีสารสนเทศ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

บทที่ 13

การถดถอย Regression

ในบทนี้เราจะศึกษาการถดถอยอย่างง่าย ซึ่งประกอบไปด้วยหัวข้อต่างๆ ดังนี้

- สหสัมพันธ์ (Correlation)
- การถดถอยเชิงเส้นอย่างง่าย (Simple Linear Regression)
- การถดถอยเชิงซ้อน (Multiple Linear Regression)

13.1 สหสัมพันธ์ (Correlation)

บ่อยครั้งที่เราจำเป็นต้องหาความสัมพันธ์ระหว่างตัวแปร 2 ตัวในชุดข้อมูล เช่น เราอาจอยากรู้ว่าอายุของผู้ใช้งานเฟซบุ๊กกับจำนวนของเพื่อนมีความสัมพันธ์กันหรือไม่ และในลักษณะใด เช่น จำนวนเพื่อนจะแปรผันตรงกับอายุของผู้ใช้งานหรือไม่ มีความสัมพันธ์กันในลักษณะเชิงเส้นหรือไม่ สามารถเขียนสมการขึ้นมาเพื่ออธิบายความสัมพันธ์ได้หรือไม่ หรืออีกตัวอย่างเช่น เราอาจอยากรู้ว่าส่วนสูงของคนกับความยาวของแขนมีความสัมพันธ์กันหรือไม่ และในลักษณะใด เช่น ความยาวของแขนแปรผันตรงกับส่วนสูงของคนใช่หรือไม่ เมื่อทราบว่าชายคนหนึ่งสูง 165 ซม. จะสามารถประมาณความยาวแขนของเขาได้หรือไม่ มีวิธีการประมาณอย่างไร เป็นต้น

เนื้อหาในบทนี้อ้างอิงจาก [4]

ปัญหา 13.1 สัมประสิทธิ์สหสัมพันธ์ (Correlation Coefficient) คืออะไร?

วิชา สัมประสิทธิ์สหสัมพันธ์ (Correlation Coefficient) คือ ค่าที่ใช้วัดว่าตัวแปร 2 ชุด เช่น x และ y มีความสัมพันธ์กันในลักษณะเชิงเส้นมากน้อยเพียงใด เรามักแทนค่าสัมประสิทธิ์สหสัมพันธ์ด้วยตัวแปร r

ปัญหา 13.2 ค่าสัมประสิทธิ์สหสัมพันธ์ มีค่าในช่วงใด?

วิชา ค่าสัมประสิทธิ์สหสัมพันธ์ หรือ r มีค่าตั้งแต่ -1 ถึง 1 กล่าวคือ $-1 \leq r \leq 1$ ถ้าค่า r เป็นบวกแสดงว่าตัวแปร 2 ตัวมีความสัมพันธ์เชิงบวก เช่น ความสูงกับความยาวแขนของคนมีความสัมพันธ์ในเชิงบวก กล่าวคือ คนที่มีส่วนสูงมากก็มีแนวโน้มที่แขนจะยาวมากขึ้นตามสัดส่วน ถ้าค่า r เป็นลบแสดงว่าตัวแปร 2 ตัวมีความสัมพันธ์เชิงลบหรือสวนทางกัน เช่น อุณหภูมิของอากาศกับยอดขายกาแฟร้อนมีความสัมพันธ์ในเชิงลบ กล่าวคือ ยิ่งอุณหภูมิสูง (อากาศร้อน) ยอดขายกาแฟร้อนก็ยิ่งลดลง เป็นต้น

ยิ่งค่า r เข้าใกล้ 1 มากก็แสดงว่าตัวแปร 2 ตัวมีความสัมพันธ์เชิงบวกยิ่งเด่นชัดมาก ยิ่งค่า r เข้าใกล้ -1 มากก็แสดงว่าตัวแปร 2 ตัวมีความสัมพันธ์เชิงลบยิ่งเด่นชัดมาก

ปัญหา 13.3 เมื่อค่า $r = 0$ หมายความว่าอย่างไร?

วิชา เมื่อค่า $r = 0$ หมายความว่า ตัวแปรสองตัวไม่มีสหสัมพันธ์กัน (uncorrelated) กล่าวคือไม่มีความสัมพันธ์กันในลักษณะเชิงเส้นนั่นเอง

ปัญหา 13.4 ค่าสัมประสิทธิ์สหสัมพันธ์ มีวิธีคำนวณอย่างไร?

วิชา กำหนด $(x_1, y_1), \dots, (x_n, y_n)$ เป็นข้อมูลลำดับที่ 1 ถึง n ของตัวแปร x และ y เราสามารถคำนวณค่าสัมประสิทธิ์สหสัมพันธ์ r ดังนี้

$$r = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right)$$

โดยที่ $\bar{x}$ คือค่าเฉลี่ยของ x , $\bar{y}$ คือค่าเฉลี่ยของ y , s_x คือค่าเบี่ยงเบนมาตรฐานของ x , และ s_y คือ ค่าเบี่ยงเบนมาตรฐานของ y


เนื่องจาก $s_x = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 / (n-1)}$ และ $s_y = \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2 / (n-1)}$ เราสามารถแทนเข้าไปในสมการข้างต้นซึ่งจะได้

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

หรือจะเขียนอีกแบบหนึ่งก็ได้คือ

$$r = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sqrt{\sum_{i=1}^n x_i^2 - n \bar{x}^2} \sqrt{\sum_{i=1}^n y_i^2 - n \bar{y}^2}}$$

ตัวอย่าง 13.1 จากรูป 13.1 ซึ่งแสดงความสัมพันธ์ระหว่างความยาวกลีบเลี้ยงและความยาวกลีบดอกของดอกไอริส (Iris) โดยมีความยาวกลีบเลี้ยง (Sepal length) บนแกน x และ ความยาวกลีบดอก (Petal length) บนแกน y ค่าสัมประสิทธิ์สหสัมพันธ์ควรเป็นอย่างไร



รูป 13.1: แผนภาพแสดงความสัมพันธ์ระหว่างความยาวกลีบเลี้ยงและความยาวกลีบดอกไอริส สายพันธุ์ Virginia

วิธีทำ จากรูป 13.1 จะเห็นว่าเมื่อความยาวกลีบเลี้ยง (x) เพิ่มขึ้น ความยาวกลีบดอก (y) ก็มีแนวโน้มเพิ่มขึ้นตาม ดังนั้นค่าสัมประสิทธิ์สหสัมพันธ์ r ควรมีเครื่องหมายเป็นบวก ซึ่งจากข้อมูลตัวอย่างนี้เมื่อคำนวณมาจะได้ค่า $r = 0.864$

ปัญหา 13.5 สหสัมพันธ์ระหว่างตัวแปร 2 ตัว x, y เป็นความสัมพันธ์ในเชิงสาเหตุและผลที่เกิด กล่าวคือ x ส่งผลให้เกิด y ใช่หรือไม่?

วิธีสนทนา ไม่ใช่ สหสัมพันธ์ระหว่างตัวแปร 2 ตัว x, y ไม่เป็นความสัมพันธ์ในเชิงสาเหตุและผลที่เกิด (Correlation is not causation) การที่ x และ y มีความสัมพันธ์กันไม่ได้หมายความว่า x ส่งผลให้เกิด y เสมอไป

เช่น เราอาจทราบว่าขนาดเท้าของเด็กมีความสัมพันธ์ในเชิงบวกกับจำนวนคำศัพท์ที่เด็กจำได้ กล่าวคือ ยิ่งเด็กมีขนาดเท้าใหญ่ขึ้นก็จะมีจำนวนคำศัพท์ที่จำได้มากขึ้น เหตุที่ความสัมพันธ์เป็นไปในลักษณะนี้เพราะเมื่อเด็กอายุมากขึ้นเท้าก็จะใหญ่ขึ้น รวมถึงมีความสามารถในการจำคำศัพท์ได้มากขึ้นด้วย แต่ไม่ได้แปลว่าขนาดเท้าที่ใหญ่เป็นสาเหตุให้เด็กจำคำศัพท์ได้มากขึ้น

ตัวอย่าง 13.2 จากค่าของตัวแปร x, y ที่กำหนดไว้ในตาราง 13.1 จงคำนวณค่าสัมประสิทธิ์สหสัมพันธ์

ตาราง 13.1: แสดงค่า x, y

x	y
2	4
3	8
7	12
4	9
9	15

วิธีทำ คำนวณค่าต่างๆ ดังนี้

$$\bar{x} = \frac{1}{5}(2 + 3 + 7 + 4 + 9) = 5$$

$$\bar{y} = \frac{1}{5}(4 + 8 + 12 + 9 + 15) = 9.6$$

$$s_x = \sqrt{\sum_{i=1}^5 \frac{(x_i - 5)^2}{4}} = 2.9154$$

$$s_y = \sqrt{\sum_{i=1}^5 \frac{(y_i - 9.6)^2}{4}} = 4.1593$$

หาค่าสัมประสิทธิ์สหสัมพันธ์ ดังนี้

$$\begin{aligned} r &= \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right) \\ &= \frac{1}{4} \sum_{i=1}^5 \left(\frac{x_i - 5}{2.9154} \right) \left(\frac{y_i - 9.6}{4.1593} \right) \\ &= 0.969 \end{aligned}$$

ดังนั้นได้ค่า $r = 0.969$

13.2 การถดถอยเชิงเส้นอย่างง่าย (Simple Linear Regression)

บ่อยครั้งที่เรามีข้อมูลแสดงความสัมพันธ์ของตัวแปร 2 ตัว เช่น ส่วนสูงและความยาวแขนของคน หรือความยาวกลีบเลี้ยงและความยาวกลีบดอก ซึ่งเมื่อเรานำข้อมูลเหล่านี้มาแสดงผลในแผนภาพการกระจาย หรือที่เรียกว่าสแกตเตอร์พล็อต (Scatter Plot) เราก็จะเห็นแนวโน้มของความสัมพันธ์ อย่างเช่นที่แสดงในรูป 13.1 เราจะเห็นแนวโน้มของความสัมพันธ์ว่า หากความยาวกลีบเลี้ยงยาวขึ้น ความยาวกลีบดอกก็ยาวขึ้นเป็นสัดส่วนที่สัมพันธ์กันด้วย และจะเป็นการดียิ่งขึ้น ถ้าหากเราสามารถหาสมการเชิงเส้นมาเชื่อมโยงความสัมพันธ์ระหว่าง 2 ตัวแปร ซึ่งการสร้างสมการเชิงเส้นมาอธิบายเชื่อมโยงความสัมพันธ์ระหว่าง 2 ตัวแปรก็คือการวิเคราะห์การถดถอยแบบเชิงเส้นนั่นเอง (Linear Regression)

ปูจฉฉ 13.6 การวิเคราะห์การถดถอยแบบเชิงเส้นคืออะไร? มีวิธีการทำอย่างไร?

วิธีฉฉฉ การวิเคราะห์การถดถอยแบบเชิงเส้น คือ การหาสมการเชิงเส้นมาอธิบายความสัมพันธ์ระหว่างตัวแปร 2 ตัว (x, y) สมการเชิงเส้นนี้หาได้โดยดูจากข้อมูล x, y ที่มี ยกตัวอย่างเช่น เราอาจต้องการสมการเชิงเส้นมาอธิบายความสัมพันธ์ระหว่างความยาวกลีบเลี้ยงและความยาวกลีบดอกของดอกไอริส ตามที่แสดงในรูป 13.2

จากรูป 13.2 จะเห็นได้ว่า เส้นตรงที่สามารถแสดงแนวโน้มของความสัมพันธ์ระหว่างตัวแปร x และ y นั้นอาจเป็นไปได้ได้หลายเส้น เช่น เราอาจลากเส้นตรงอีกเส้นที่มีความชันต่างไปจากเส้นที่แสดงในรูป 13.2 เล็กน้อยก็ได้ แต่ทั้งนี้เราควรเลือก “เส้นที่ดีที่สุด” มาเป็นเส้นถดถอย ซึ่งวิธีการเลือกเส้นที่ดีที่สุดจะกล่าวถึงต่อไป

ปูจฉฉ 13.7 กำหนด x และ y เป็นตัวแปรในชุดข้อมูล เรามีวิธีเขียนสมการเชิงเส้นแสดงความสัมพันธ์ระหว่าง x และ y อย่างไร?


วิธีฉฉฉ เขียนเป็นสมการได้ดังนี้

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

เราเรียก y_i ว่าตัวแปรตาม (Dependent Variable), เรียก x_i ว่า ตัวแปรอิสระ (Independent Variable), เรียก β_0, β_1 ว่า สัมประสิทธิ์การถดถอย (Regression Coefficients) และเรียก ϵ_i ว่าความผิดพลาด (Error)

ในความเป็นจริงแล้วเราไม่สามารถหาค่า β_0 และ β_1 ได้อย่างแม่นยำ 100% เนื่องจากความผิดพลาด ϵ_i ที่เกิดขึ้น แต่เราสามารถประมาณหาค่า β_0 และ β_1 ได้ ซึ่งเราจะเขียนเป็นสมการดังนี้

$$y = \hat{\beta}_0 + \hat{\beta}_1 x$$




รูป 13.2: แผนภาพแสดงความสัมพันธ์ระหว่างความยาวกลีบเลี้ยงและความยาวกลีบดอกไอริส สายพันธุ์ Virginica และเส้นถดถอย

สมการเส้นตรง $y = \hat{\beta}_0 + \hat{\beta}_1 x$ นี้จะถูกใช้เป็นสมการถดถอยสำหรับฟิต (Fit) ข้อมูล x, y

ปัญหา 13.8 เส้นตรงที่ดีที่สุด ในการแสดงแนวโน้มของความสัมพันธ์ระหว่างตัวแปร x และตัวแปร y ควรเป็นอย่างไร?

วิธีชนา ควรเป็นเส้นที่ทำให้ส่วนต่าง (Residual) ระหว่าง “ค่าจริง” กับ “ค่าบนเส้น” น้อยที่สุด

กำหนด $e_i = y_i - \hat{y}_i$ เป็นส่วนต่างระหว่าง y_i ซึ่งเป็นค่าจริงของตัวแปร y ในลำดับที่ i และ $\hat{y}_i$ ซึ่งเป็นค่าที่ได้จากสมการเส้นตรง $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ ส่วนต่าง e_i นี้แสดงให้เห็นในรูป 13.3 ซึ่งก็คือระยะห่างในแนวตั้งระหว่างค่า y_i (จุดข้อมูล) กับค่า $\hat{y}_i$ บนเส้นตรงที่เราสร้างขึ้นนั่นเอง เส้นตรงที่ดีที่สุดคือเส้นที่ทำให้ผลรวมของส่วนต่างน้อยที่สุด หรือเส้นที่ทำให้ $\sum_{i=1}^n e_i^2$ มีค่าต่ำที่สุดนั่นเอง



รูป 13.3: แผนภาพแสดงความสัมพันธ์ระหว่างความยาวกลีบเลี้ยงและความยาวกลีบดอกไอริส สายพันธุ์ Virginica และเส้นถดถอย ค่า e_i คือส่วนต่างระหว่างค่าจริงของข้อมูล (y_i) กับค่าที่อยู่บนเส้นถดถอยที่สร้างขึ้น ($\hat{y}_i$)

ปูจจา 13.9 สมการเส้นตรงที่ดีที่สุดสำหรับใช้เป็นเส้นถดถอย มีสมการอย่างไร?

วิธีทนา มีสมการซึ่งหาได้ดังนี้ เนื่องจากเราต้องการทำให้ $\sum_{i=1}^n e_i^2$ มีค่าต่ำสุด จึงต้องมาดู e_i ก่อน เขียนสมการของ e_i ได้ดังนี้

$$e_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

ดังนั้น $\hat{\beta}_0, \hat{\beta}_1$ เป็นตัวที่จะทำให้ผลรวม $\sum_{i=1}^n e_i^2$ ต่ำที่สุด กำหนดค่า S แทนผลรวมดังนี้

$$S = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

เราสามารถหาค่า $\hat{\beta}_0$ และ $\hat{\beta}_1$ ที่ทำให้สมการข้างต้นมีค่าต่ำสุดได้โดยการหาอนุพันธ์เพื่อดูจุดต่ำสุดของสมการข้างต้น กล่าวคือ ต้องหาค่า $\hat{\beta}_0$ และ $\hat{\beta}_1$ ที่เป็นคำตอบของระบบสมการต่อไปนี้

$$\begin{aligned} \frac{\partial S}{\partial \hat{\beta}_0} &= - \sum_{i=1}^n 2(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ \frac{\partial S}{\partial \hat{\beta}_1} &= - \sum_{i=1}^n 2x_i(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \end{aligned}$$

ซึ่งเมื่อแก้ระบบสมการนี้แล้วจะได้คำตอบคือ

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \end{aligned}$$

สำหรับผู้สนใจสามารถดูรายละเอียดวิธีการหาคำตอบของสมการเพิ่มเติมได้จาก [4]

ตัวอย่าง 13.3 จากค่าของตัวแปร x, y ที่กำหนดไว้ในตาราง 13.2 จงหาสมการถดถอยสำหรับข้อมูลชุดนี้

วิธีทำ หาดตามขั้นตอนดังนี้

ตาราง 13.2: แสดงค่า x, y

x	y
2	4
3	8
7	12
4	9
9	15

1. หาค่าที่จำเป็นต่างๆ ดังนี้

$$\bar{x} = \frac{1}{5}(2 + 3 + 7 + 4 + 9) = 5$$

$$\bar{y} = \frac{1}{5}(4 + 8 + 12 + 9 + 15) = 9.6$$

$$\sum_{i=1}^5 (x_i - \bar{x})^2 = 34$$

$$\sum_{i=1}^5 (x_i - \bar{x})(y_i - \bar{y}) = 47$$

2. หาค่า $\hat{\beta}_1$

$$\begin{aligned}\hat{\beta}_1 &= \frac{\sum_{i=1}^5 (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^5 (x_i - \bar{x})^2} \\ &= \frac{47}{34} = 1.3824\end{aligned}$$

3. หาค่า $\hat{\beta}_0$


$$\begin{aligned}\hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} \\ &= 9.6 - (1.3824 \times 5) \\ &= 2.6882\end{aligned}$$

4. เขียนสมการถดถอย คือ

$$y = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$y = 2.6882 + 1.3824 x$$

เมื่อวาดสมการถดถอยและจุดข้อมูล (x, y) จะได้ดังรูป 13.4



รูป 13.4: จุดข้อมูล (x, y) และเส้นถดถอย

13.3 การถดถอยเชิงซ้อน (Multiple Linear Regression)

ในส่วนของแล้ว เราได้ศึกษาวิธีการสร้างตัวแบบการถดถอยเชิงเส้นอย่างง่าย กล่าวคือ ตัวแปรตามหรือ y นั้น เป็นฟังก์ชันของตัวแปรอิสระหรือ x เพียงตัวเดียว ในการประยุกต์ใช้งานจริง เราพบว่าบ่อยครั้งที่ตัวแปรตามนั้นจะเป็นฟังก์ชันของตัวแปรอิสระมากกว่าหนึ่งตัว ยกตัวอย่างเช่น ราคาบ้านอาจจะขึ้นอยู่กับตัวแปรอิสระหลายๆตัว เช่น ขนาดพื้นที่ของบ้าน จำนวนชั้น และทำเลที่ตั้งของบ้าน เป็นต้น การสร้างตัวแบบการถดถอยเชิงซ้อน (Multiple Linear Regression Model) ก็คือการนำข้อมูลจากหลายๆปัจจัยที่ส่งผลต่อตัวแปรตาม มาพิจารณาร่วมกันนั่นเอง

ปฏิจา 13.10 กำหนด $x_1, x_2, \dots, x_p$ เป็นตัวแปรอิสระจำนวน p ตัวในชุดข้อมูล และ y เป็นตัวแปรตาม สมการเชิงเส้นสำหรับแสดงความสัมพันธ์ระหว่างตัวแปรตามและตัวแปรอิสระมีลักษณะอย่างไร?

วิธีชนา มีลักษณะดังนี้

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \epsilon_i$$

และในทำนองเดียวกันกับกรณีสมการถดถอยอย่างง่าย เราจะประมาณค่า y ตามสมการดังนี้

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p$$

โดยที่ $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ คือค่าประมาณของสัมประสิทธิ์การถดถอย

ปฏิจา 13.11 สมการเชิงเส้นที่ดีที่สุดสำหรับใช้เป็นสมการถดถอยในกรณีที่ตัวแปรอิสระมีหลายตัว หาได้อย่างไร?

วิธีชนา เช่นเดียวกันกับกรณีสมการถดถอยอย่างง่าย เราต้องทำให้ส่วนต่างระหว่างค่าจริง (y_i) กับค่าที่ได้จากสมการ ($\hat{y}_i$) ต่างกันน้อยที่สุด ซึ่งส่วนต่างเขียนได้ตามสมการ


$$\begin{aligned} e_i &= y_i - \hat{y}_i \\ &= y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \dots + \hat{\beta}_p x_{pi}) \end{aligned}$$

ผลรวมกำลังสองของส่วนต่างคือ

$$S = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n \left(y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \dots + \hat{\beta}_p x_{pi}) \right)^2$$

สมการเชิงเส้นที่ดีที่สุดที่ควรใช้เป็นสมการถดถอยก็คือ สมการเชิงเส้นที่มีสัมประสิทธิ์ $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ ที่ทำให้ $\sum_{i=1}^n e_i^2$ ในสมการข้างต้นมีค่าน้อยที่สุด ซึ่งสามารถหาได้โดยหาอนุพันธ์ต่างๆของสมการข้างต้นซึ่งก็คือ $\frac{\partial S}{\partial \hat{\beta}_0}, \frac{\partial S}{\partial \hat{\beta}_1}, \dots, \frac{\partial S}{\partial \hat{\beta}_p}$ แล้วตั้งอนุพันธ์เหล่านี้ให้มีค่าเท่ากับ 0 และแก้ระบบสมการเพื่อหาจุดต่ำสุด คำตอบของระบบสมการที่ได้ก็คือ ค่า $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ ที่จะทำให้ $\sum_{i=1}^n e_i^2$ มีค่าน้อยที่สุด

อย่างไรก็ตาม ในทางปฏิบัติเราจะใช้เครื่องมือ เช่น โปรแกรมคอมพิวเตอร์ ในการคำนวณหาค่าสัมประสิทธิ์เหล่านี้ ดังนั้นเราไม่จำเป็นต้องคำนวณเองด้วยมือ




รูป 13.5: แผนภาพแสดงความสัมพันธ์ระหว่างประสิทธิภาพการใช้พลังงาน (mpg) และน้ำหนักของรถ (wt) และเส้นถดถอย

ตัวอย่าง 13.4 ในตัวอย่างนี้ เราจะลองดูตัวอย่างสหสัมพันธ์ระหว่างประสิทธิภาพด้านการใช้พลังงานของรถ ซึ่งวัดในหน่วย Miles/gallon (mpg) กับตัวแปรอิสระอื่นๆ เช่น น้ำหนักของรถในหน่วยตัน และกำลังของรถในหน่วยแรงม้า

รูป 13.5 แสดงแผนภาพการกระจายระหว่าง ประสิทธิภาพการใช้พลังงาน (mpg) กับ ตัวแปรอิสระ 1 ตัว คือ น้ำหนักของรถ (wt) ในหน่วยตัน จากรูป จะสังเกตได้ว่าความชันของเส้นถดถอยเป็นลบ ซึ่งกล่าวได้ว่าประสิทธิภาพการใช้พลังงานกับน้ำหนักของรถ มีความสัมพันธ์กันในเชิงลบ กล่าวคือ เมื่อน้ำหนักรถเพิ่มมากขึ้น ประสิทธิภาพการใช้พลังงานลดลง หรือ ระยะทางที่รถวิ่งได้ต่อน้ำมันหนึ่งแกลลอนลดลงนั่นเอง เมื่อใช้โปรแกรมคำนวณจะได้สมการถดถอยดังนี้

$$y = 37.2851 - 5.3444x$$

เราสามารถนำสมการถดถอยนี้ไปประเมินหาประสิทธิภาพการใช้พลังงานได้ เช่น เราอาจจะอยากประเมินว่ารถที่มีน้ำหนัก 4 ตัน น่าจะมีค่าประสิทธิภาพการใช้พลังงานเท่าใด ซึ่งทำได้โดยแทนค่า $x = 4$ เข้าไปในสมการถดถอยจะได้ $y = 15.9075$ ดังนั้นสามารถประเมินได้ว่า รถที่มีน้ำหนัก 4 ตัน น่าจะมีค่าประสิทธิภาพการใช้พลังงานเท่ากับ 15.9075 miles/gallon




รูป 13.6: แผนภาพแสดงความสัมพันธ์ระหว่างประสิทธิภาพการใช้พลังงาน (mpg) และกำลังของรถ (hp) และเส้นถดถอย

ประสิทธิภาพด้านการใช้พลังงานของรถ ยังมีสหสัมพันธ์กับตัวแปรอื่นๆ อีก เช่น กำลังของรถในหน่วยแรงม้า รูป 13.6 แสดงแผนภาพการกระจายระหว่าง ประสิทธิภาพการใช้พลังงาน (mpg) กับ ตัวแปรอิสระ 1 ตัว คือ กำลังของรถ (hp) ในหน่วยแรงม้า จากรูป จะสังเกตได้ว่าความชันของเส้นถดถอยเป็นลบ ซึ่งกล่าวได้ว่าประสิทธิภาพการใช้พลังงานกับกำลังของรถ มีความสัมพันธ์กันในเชิงลบ กล่าวคือ เมื่อกำลังของรถเพิ่มมากขึ้น ประสิทธิภาพการใช้พลังงานลดลง หรือ ระยะทางที่รถวิ่งได้ต่อน้ำมันหนึ่งแกลลอนลดลงนั่นเอง เมื่อใช้โปรแกรมคำนวณจะได้สมการถดถอยดังนี้

$$y = 30.0988 - 0.0682x$$

เราสามารถนำสมการถดถอยนี้ไปประเมินหาประสิทธิภาพการใช้พลังงานได้ เช่น เราอาจจะอยากประเมินว่ารถที่มีกำลัง 100 แรงม้า น่าจะมีค่าประสิทธิภาพการใช้พลังงานเท่าใด ซึ่งทำได้โดยแทนค่า $x = 100$ เข้าไปในสมการถดถอย จะได้ $y = 23.2788$ ดังนั้นสามารถประเมินได้ว่ารถที่มีกำลัง 100 แรงม้า น่าจะมีค่าประสิทธิภาพการใช้พลังงานเท่ากับ 23.2788 miles/gallon

นอกจากนี้ เรายังสามารถใช้การถดถอยเชิงซ้อน มาประเมินความสัมพันธ์ระหว่างประสิทธิภาพการใช้พลังงานกับตัวแปรอิสระ 2 ตัวร่วมกัน รูป 13.7 แสดงแผนภาพการกระจายระหว่างประสิทธิภาพการใช้



รูป 13.7: แผนภาพการกระจายระหว่างประสิทธิภาพการใช้พลังงาน (mpg) กับ ตัวแปรอิสระ 2 ตัว คือ น้ำหนักของรถ (wt) ในหน่วยตัน และกำลังของรถ (hp) ในหน่วยแรงม้า และระนาบถดถอย

พลังงาน (mpg) กับ ตัวแปรอิสระ 2 ตัว คือ น้ำหนักของรถ (wt) ในหน่วยตัน และกำลังของรถ (hp) ในหน่วยแรงม้า เนื่องจากมีตัวแปรอิสระ 2 ตัว แผนภาพการกระจายจึงมี 3 มิติ เราสามารถสร้างระนาบถดถอยสำหรับความสัมพันธ์นี้ เมื่อใช้โปรแกรมคำนวณจะได้สมการถดถอยดังนี้

$$y = 37.2272 - 3.8778x_1 - 0.0317x_2$$

โดยที่ x_1 คือน้ำหนักรถในหน่วยตัน และ x_2 คือกำลังของรถในหน่วยแรงม้า เราสามารถนำสมการถดถอยนี้ไปประเมินหาประสิทธิภาพการใช้พลังงานได้ เช่น เราอาจจะอยากประเมินว่า รถที่มีน้ำหนัก 3 ตัน มีกำลัง 200 แรงม้า น่าจะมีค่าประสิทธิภาพการใช้พลังงานเท่าใด ซึ่งทำได้โดยแทนค่า $x_1 = 3$ และ $x_2 = 200$ เข้าไปในสมการถดถอย จะได้ $y = 19.2538$ ดังนั้นสามารถประเมินได้ว่า รถที่มีน้ำหนัก 3 ตัน มีกำลัง 200 แรงม้า น่าจะมีค่าประสิทธิภาพการใช้พลังงานเท่ากับ 19.2538 miles/gallon

บรรณานุกรม

- [1] S. Ross, *A First Course in Probability*, 9th ed. Pearson, 2012.
- [2] D. P. Bertsekas and J. N. Tsitsiklis, *Introduction to Probability*, 2nd ed. Athena Scientific, 2008.
- [3] A. Leon-Garcia, *Probability, Statistics, and Random Processes for Electrical Engineering*, 3rd ed. Pearson, 2008.
- [4] W. Navidi, *Statistics for Engineers and Scientists*, 3rd ed. McGraw-Hill, 2010.